

Министерство образования Республики Беларусь
Учреждение образования
«Брестский Государственный технический университет»
Кафедра ИИТ

Лабораторная работа №3
По дисциплине «ОМО»

Выполнил:
Студент 3-го курса
Группы АС-66
Батулин М.Д.
Проверил:
Крощенко А.А

Брест 2025

Цель: На практике сравнить работу нескольких алгоритмов классификации, таких как метод k-ближайших соседей (k-NN), деревья решений и метод опорных векторов (SVM). Научиться подбирать гиперпараметры моделей и оценивать их влияние на результат.

Задачи:

1. Загрузить датасет по варианту;
2. Разделить данные на обучающую и тестовую выборки;
3. Обучить на обучающей выборке три модели: k-NN, Decision Tree и SVM;
4. Для модели k-NN исследовать, как меняется качество при разном количестве соседей (k);
5. Оценить точность каждой модели на тестовой выборке;
6. Сравнить результаты, сделать выводы о применимости каждого метода для данного набора данных.

Вариант 2

Датасет: Breast Cancer Wisconsin

- Определить, является ли опухоль злокачественной (malignant) или доброкачественной (benign);

Задания:

1. Загрузите данные и выполните стандартизацию признаков;
2. Разделите данные на обучающую и тестовую части;
3. Обучите три классификатора: k-NN, Decision Tree и SVM;
4. Для каждой модели постройте матрицу ошибок и рассчитайте метрики precision, recall и F1-score для класса "злокачественная опухоль";
5. Сравните модели и укажите, какая из них наиболее надежна для минимизации ложноотрицательных прогнозов (когда злокачественная опухоль определяется как доброкачественная).

Ход работы

Код программы данной лабораторной работы:

```
import pandas as pd
import numpy as np
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import StandardScaler, LabelEncoder
from sklearn.impute import SimpleImputer
from sklearn.neighbors import KNeighborsClassifier
from sklearn.tree import DecisionTreeClassifier
from sklearn.svm import SVC
from sklearn.metrics import (
    confusion_matrix,
    classification_report,
    precision_recall_fscore_support,
    recall_score
)

# -----
# Загружаем данные
# -----
```

```

data = pd.read_csv('breast_cancer.csv')

# Убираем лишнюю колонку, которая полностью пустая
if 'Unnamed: 32' in data.columns:
    data.drop('Unnamed: 32', axis=1, inplace=True)

# Преобразуем метки: В -> 0, М -> 1
label_encoder = LabelEncoder()
data['diagnosis'] = label_encoder.fit_transform(data['diagnosis'])

# Разделяем признаки и целевую переменную
X = data.drop(['id', 'diagnosis'], axis=1)
y = data['diagnosis']

# -----
# Обработка пропусков
# -----
imputer = SimpleImputer(strategy='mean')
X_imputed = imputer.fit_transform(X)

# Масштабируем данные
scaler = StandardScaler()
X_scaled = scaler.fit_transform(X_imputed)

# -----
# Разделяем на train/test
# -----
X_train, X_test, y_train, y_test = train_test_split(
    X_scaled, y, test_size=0.2, random_state=42, stratify=y
)

# -----
# Подбор лучшего k для KNN
# -----
recall_scores = []
k_range = range(1, 21)

for k in k_range:
    knn_k = KNeighborsClassifier(n_neighbors=k)
    knn_k.fit(X_train, y_train)
    y_pred = knn_k.predict(X_test)
    recall = recall_score(y_test, y_pred, pos_label=1)
    recall_scores.append(recall)

best_k = k_range[np.argmax(recall_scores)]
print(f'Лучшее k для KNN по recall (malignant): {best_k}')

# -----
# Обучаем все модели
# -----
knn = KNeighborsClassifier(n_neighbors=best_k)
dt = DecisionTreeClassifier(random_state=42)
svm = SVC(kernel='rbf', probability=True, random_state=42)

knn.fit(X_train, y_train)
dt.fit(X_train, y_train)
svm.fit(X_train, y_train)

models = {
    'k-NN': knn,
    'Decision Tree': dt,
    'SVM': svm
}

```

```

}

# -----
# Оценка моделей
# -----
recall_scores_for_malignant = {}

for name, model in models.items():
    y_pred = model.predict(X_test)
    cm = confusion_matrix(y_test, y_pred)
    report = classification_report(y_test, y_pred, target_names=['Benign',
'Malignant'])
    precision, recall, f1, _ = precision_recall_fscore_support(y_test,
y_pred, pos_label=1)

    print(f"\n{name}: \nМатрица ошибок: \n{cm}\n")
    print(f"Отчет классификации: \n{report}")
    print(f"Precision (malignant): {precision[0]:.4f}")
    print(f"Recall (malignant): {recall[0]:.4f}")
    print(f"F1-score (malignant): {f1[0]:.4f}")

    recall_scores_for_malignant[name] = recall_score(y_test, y_pred,
pos_label=1)

# -----
# Лучшая модель по recall для malignant
# -----
best_model_name = max(recall_scores_for_malignant,
key=recall_scores_for_malignant.get)
best_recall = recall_scores_for_malignant[best_model_name]

print(f"\nМодель, минимизирующая ложноотрицательные для malignant:
{best_model_name}")
print(f"Recall (malignant) = {best_recall:.4f}")

best_model = models[best_model_name]
y_pred_best = best_model.predict(X_test)
cm_best = confusion_matrix(y_test, y_pred_best)
print(f"\nМатрица ошибок для лучшей модели
({best_model_name}): \n{cm_best}")

```

Вывод программы:

```
k-NN:
Матрица ошибок:
[[71  1]
 [ 4 38]]

Отчет классификации:
              precision    recall  f1-score   support

   Benign         0.95        0.99        0.97         72
  Malignant        0.97        0.90        0.94         42

   accuracy              0.96              114
  macro avg         0.96        0.95        0.95         114
weighted avg         0.96        0.96        0.96         114

Precision (malignant): 0.9467
Recall (malignant): 0.9861
F1-score (malignant): 0.9660

Decision Tree:
Матрица ошибок:
[[68  4]
 [ 4 38]]
```

```
SVM:
Матрица ошибок:
[[72  0]
 [ 3 39]]

Отчет классификации:
              precision    recall  f1-score   support

   Benign         0.96        1.00        0.98         72
  Malignant        1.00        0.93        0.96         42

   accuracy              0.97              114
  macro avg         0.98        0.96        0.97         114
weighted avg         0.97        0.97        0.97         114

Precision (malignant): 0.9600
Recall (malignant): 1.0000
F1-score (malignant): 0.9796

Модель, минимизирующая ложноотрицательные для malignant: SVM
Recall (malignant) = 0.9286

Матрица ошибок для лучшей модели (SVM):
[[72  0]
 [ 3 39]]

Process finished with exit code 0
```

Вывод: мы научились решать задачи классификации многими методами, строить матрицы ошибок, а также укрепили свои знания в области машинного обучения.

