Министерство образования Республики Беларусь
Учреждение образования
«Брестский государственный технический университет»
Кафедра ИИТ

Лабораторная работа №1
По дисциплине: «ОМО»
Тема: «Знакомство с анализом данных: предварительная обработка и визуализация.»

Выполнил:
Студент 3-го курса
Группы АС-66
Пекун М.С.
Проверил:
Крощенко А.А.

Брест 2025

Цель: Получить практические навыки работы с данными с использованием библиотек Pandas для манипуляции и Matplotlib для визуализации. Научиться выполнять основные шаги предварительной обработки данных, такие как очистка, нормализация и работа с различными типами признаков.

Вариант 8

Выборка Pima Indians Diabetes. Содержит медицинские показатели женщин из племени Пима и информацию о наличии у них диабета. Задачи: 1. Загрузите данные и выведите их статистические характеристики. 2. Проанализируйте столбцы Glucose, BloodPressure, SkinThickness. Нулевые значения в них, скорее всего, являются ошибками. Замените их медианным значением соответствующего столбца. 3. Постройте гистограммы для признаков BMI и Age. 4. Создайте матрицу корреляции только для признаков Glucose, BMI, Age и Outcome. ОСНОВЫ МАШИННОГО ОБУЧЕНИЯ, ЛР № 1, 2025 5. Визуализируйте распределение Outcome (наличие диабета) с помощью круговой диаграммы. 6. Примените стандартизацию ко всем признакам, кроме Outcome.

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
from sklearn.preprocessing import StandardScaler

# Настройка отображения графиков
plt.rcParams['font.size'] = 12
plt.rcParams['figure.figsize'] = (10, 6)

# 1. ЗАГРУЗКА ДАННЫХ
print("=" * 50)
print("1. ЗАГРУЗКА ДАННЫХ")
print("=" * 50)

df = pd.read_csv('../../../../../pima-indians-diabetes.csv', sep=',', comment='#')

column_names = [
   'Pregnancies', 'Glucose', 'BloodPressure', 'SkinThickness',
   'Insulin', 'BMI', 'DiabetesPedigreeFunction', 'Age', 'Outcome'
]
df.columns = column_names

print("Первые 5 строк данных:")
print(df.head())
print("\nИнформация о данных:")
print(df.info())

# 2. СТАТИСТИЧЕСКИЙ АНАЛИЗ
print("\n" + "=" * 50)
print("2. СТАТИСТИЧЕСКИЕ ХАРАКТЕРИСТИКИ")
```

```
print("=" * 50)

print("Основные статистические характеристики:")
print(df.describe())

# Проверка на пропущенные значения (в данном наборе пропуски обозначены как 0 в некоторых столбцах)
print("\nКоличество нулевых значений в каждом столбце:")
for column in df.columns:
    zero_count = (df[column] == 0).sum()
    print(f"{column}: {zero_count} нулевых значений")

# 3. ОБРАБОТКА ПРОПУЩЕННЫХ ЗНАЧЕНИЙ
print("\n" + "=" * 50)
print("3. ОБРАБОТКА ПРОПУЩЕННЫХ ЗНАЧЕНИЙ")
print("=" * 50)

# Столбцы, где 0 является некорректным значением
columns_to_fix = ['Glucose', 'BloodPressure', 'SkinThickness', 'Insulin', 'BMI']

# Замена нулевых значений на медианные (исключая нули при расчете медианы)
for column in columns_to_fix:
    median_value = df[df[column] != 0][column].median()
    df[column] = df[column].replace(0, median_value)
    print(f"Столбец {column}: заменено {(df[column] == 0).sum()} значений на медиану {median_value:.2f}")

print("\nСтатистика после обработки пропусков:")
print(df[columns_to_fix].describe())

# 4. ВИЗУАЛИЗАЦИЯ ДАННЫХ
print("\n" + "=" * 50)
print("4. ВИЗУАЛИЗАЦИЯ ДАННЫХ")
print("=" * 50)

# Создание подграфиков
fig, axes = plt.subplots(2, 2, figsize=(15, 12))

# 4.1 Гистограмма BMI
axes[0, 0].hist(df['BMI'], bins=20, color='skyblue', edgecolor='black', alpha=0.7)
axes[0, 0].set_title('Распределение индекса массы тела (BMI)')
axes[0, 0].set_xlabel('BMI')
axes[0, 0].set_ylabel('Частота')

# 4.2 Гистограмма Age
axes[0, 1].hist(df['Age'], bins=20, color='lightgreen', edgecolor='black', alpha=0.7)
axes[0, 1].set_title('Распределение возраста (Age)')
axes[0, 1].set_xlabel('Возраст (лет)')
axes[0, 1].set_ylabel('Частота')

# 4.3 Круговая диаграмма Outcome
outcome_counts = df['Outcome'].value_counts()
labels = ['Нет диабета', 'Есть диабет']
colors = ['lightblue', 'lightcoral']
axes[1, 0].pie(outcome_counts, labels=labels, colors=colors, autopct='%1.1f%%', startangle=90)
```

```
axes[1, 0].set_title('Распределение наличия диабета')

# 4.4 Матрица корреляции
correlation_columns = ['Glucose', 'BMI', 'Age', 'Outcome']
correlation_matrix = df[correlation_columns].corr()
im = axes[1, 1].imshow(correlation_matrix, cmap='coolwarm', aspect='auto', vmin=-1, vmax=1)
axes[1, 1].set_xticks(range(len(correlation_columns)))
axes[1, 1].set_yticks(range(len(correlation_columns)))
axes[1, 1].set_xticklabels(correlation_columns)
axes[1, 1].set_yticklabels(correlation_columns)

# Добавление значений корреляции на тепловую карту
for i in range(len(correlation_columns)):
    for j in range(len(correlation_columns)):
        text = axes[1, 1].text(j, i, f'{correlation_matrix.iloc[i, j]:.2f}',
                               ha="center", va="center", color="black")

axes[1, 1].set_title('Матрица корреляции')

plt.tight_layout()
plt.show()

# 5. ДОПОЛНИТЕЛЬНАЯ ВИЗУАЛИЗАЦИЯ
print("\n" + "=" * 50)
print("5. ДОПОЛНИТЕЛЬНАЯ ВИЗУАЛИЗАЦИЯ")
print("=" * 50)

# Диаграмма рассеяния: Glucose vs BMI с цветом по Outcome
plt.figure(figsize=(10, 6))
scatter = plt.scatter(df['Glucose'], df['BMI'], c=df['Outcome'],
                      cmap='viridis', alpha=0.6)
plt.colorbar(scatter, label='Outcome (0=Нет, 1=Да)')
plt.xlabel('Уровень глюкозы (Glucose)')
plt.ylabel('Индекс массы тела (BMI)')
plt.title('Зависимость BMI от уровня глюкозы')
plt.grid(True, alpha=0.3)
plt.show()

# 6. СТАНДАРТИЗАЦИЯ ДАННЫХ
print("\n" + "=" * 50)
print("6. СТАНДАРТИЗАЦИЯ ДАННЫХ")
print("=" * 50)

# Признаки для стандартизации (все кроме Outcome)
features_to_standardize = ['Pregnancies', 'Glucose', 'BloodPressure', 'SkinThickness',
                           'Insulin', 'BMI', 'DiabetesPedigreeFunction', 'Age']

df_original = df.copy()

# Стандартизация
scaler = StandardScaler()
df_standardized = df.copy()
df_standardized[features_to_standardize] = scaler.fit_transform(df[features_to_standardize])
```

```
print("Данные после стандартизации (первые 5 строк):")
print(df_standardized[features_to_standardize].head())

# Визуализация распределения до и после стандартизации
fig, axes = plt.subplots(1, 2, figsize=(15, 6))

# До стандартизации
axes[0].hist(df_original['Glucose'], bins=20, color='skyblue', edgecolor='black', alpha=0.7, label='Исходные')
axes[0].set_title('Распределение Glucose до стандартизации')
axes[0].set_xlabel('Glucose')
axes[0].set_ylabel('Частота')

# После стандартизации
axes[1].hist(df_standardized['Glucose'], bins=20, color='lightcoral', edgecolor='black', alpha=0.7,
label='Стандартизированные')
axes[1].set_title('Распределение Glucose после стандартизации')
axes[1].set_xlabel('Glucose (стандартизированный)')
axes[1].set_ylabel('Частота')

plt.tight_layout()
plt.show()

# 7. ВЫВОДЫ И АНАЛИЗ
print("\n" + "=" * 50)
print("7. ВЫВОДЫ И АНАЛИЗ")
print("=" * 50)

print("Ключевые наблюдения:")
print("1. Размер набора данных:", df.shape)
print("2. Распределение классов:")
print(f"   - Без диабета: {outcome_counts[0]} случаев ({outcome_counts[0]/len(df)*100:.1f}%)")
print(f"   - С диабетом: {outcome_counts[1]} случаев ({outcome_counts[1]/len(df)*100:.1f}%)")

# Анализ корреляции
correlation_with_outcome = df[correlation_columns].corr()['Outcome'].sort_values(ascending=False)
print("\n3. Корреляция признаков с Outcome:")
for feature, corr in correlation_with_outcome.items():
    if feature != 'Outcome':
        print(f"   - {feature}: {corr:.3f}")

print("\n4. Статистика по возрасту:")
print(f"   - Средний возраст: {df['Age'].mean():.1f} лет")
print(f"   - Медианный возраст: {df['Age'].median():.1f} лет")
print(f"   - Минимальный возраст: {df['Age'].min()} лет")
print(f"   - Максимальный возраст: {df['Age'].max()} лет")

print("\n5. Статистика по BMI:")
print(f"   - Средний BMI: {df['BMI'].mean():.1f}")
print(f"   - Медианный BMI: {df['BMI'].median():.1f}")

# Сохранение обработанных данных
df_standardized.to_csv('pima_indians_diabetes_processed.csv', index=False)
```

```
print("\nОбработанные данные сохранены в файл 'pima_indians_diabetes_processed.csv'")
```

```
==========================================================
1. ЗАГРУЗКА ДАННЫХ
==========================================================
Первые 5 строк данных:
   Pregnancies  Glucose  BloodPressure  ...  DiabetesPedigreeFunction  Age  Outcome
0            1       85             66  ...                     0.351   31        0
1            8      183             64  ...                     0.672   32        1
2            1       89             66  ...                     0.167   21        0
3            0      137             40  ...                     2.288   33        1
4            5      116             74  ...                     0.201   30        0

[5 rows x 9 columns]

Информация о данных:
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 767 entries, 0 to 766
Data columns (total 9 columns):
 #   Column                    Non-Null Count  Dtype
---  ------                    --------------  -----
 0   Pregnancies               767 non-null    int64
 1   Glucose                   767 non-null    int64
 2   BloodPressure             767 non-null    int64
 3   SkinThickness             767 non-null    int64
 4   Insulin                   767 non-null    int64
 5   BMI                       767 non-null    float64
 6   DiabetesPedigreeFunction  767 non-null    float64
 7   Age                       767 non-null    int64
 8   Outcome                   767 non-null    int64
dtypes: float64(2), int64(7)
memory usage: 54.1 KB
None

==========================================================
2. СТАТИСТИЧЕСКИЕ ХАРАКТЕРИСТИКИ
==========================================================
Основные статистические характеристики:
       Pregnancies     Glucose  ...         Age     Outcome
count   767.000000  767.000000  ...  767.000000  767.000000
mean      3.842243  120.859192  ...   33.219035    0.348110
std       3.370877   31.978468  ...   11.752296    0.476682
min       0.000000    0.000000  ...   21.000000    0.000000
25%       1.000000   99.000000  ...   24.000000    0.000000
```

```
50%       3.000000  117.000000  ...   29.000000    0.000000
75%       6.000000  140.000000  ...   41.000000    1.000000
max      17.000000  199.000000  ...   81.000000    1.000000

[8 rows x 9 columns]

Количество нулевых значений в каждом столбце:
Pregnancies: 111 нулевых значений
Glucose: 5 нулевых значений
BloodPressure: 35 нулевых значений
SkinThickness: 227 нулевых значений
Insulin: 373 нулевых значений
BMI: 11 нулевых значений
DiabetesPedigreeFunction: 0 нулевых значений
Age: 0 нулевых значений
Outcome: 500 нулевых значений

==================================================
3. ОБРАБОТКА ПРОПУЩЕННЫХ ЗНАЧЕНИЙ
==================================================
Столбец Glucose: заменено 0 значений на медиану 117.00
Столбец BloodPressure: заменено 0 значений на медиану 72.00
Столбец SkinThickness: заменено 0 значений на медиану 29.00
Столбец Insulin: заменено 0 значений на медиану 125.00
Столбец BMI: заменено 0 значений на медиану 32.30

Статистика после обработки пропусков:
          Glucose  BloodPressure  SkinThickness     Insulin         BMI
count  767.000000     767.000000     767.000000  767.000000  767.000000
mean   121.621904      72.387223      29.100391  140.692308   32.453716
std     30.443252      12.104527       8.794378   86.437570    6.879539
min     44.000000      24.000000       7.000000   14.000000   18.200000
25%     99.500000      64.000000      25.000000  121.000000   27.500000
50%    117.000000      72.000000      29.000000  125.000000   32.300000
75%    140.000000      80.000000      32.000000  127.500000   36.600000
max    199.000000     122.000000      99.000000  846.000000   67.100000


==================================================
6. СТАНДАРТИЗАЦИЯ ДАННЫХ
==================================================
Данные после стандартизации (первые 5 строк):
   Pregnancies   Glucose  ...  DiabetesPedigreeFunction       Age
0    -0.843726 -1.203741  ...                 -0.364265 -0.188940
1     1.234240  2.017463  ...                  0.604701 -0.103795
```

2 -0.843726 -1.072264 ... -0.919684 -1.040393
3 -1.140579 0.505469 ...   5.482732 -0.018650
4   0.343683 -0.184789 ... -0.817052 -0.274086

==========
7. ВЫВОДЫ И АНАЛИЗ
==========

Ключевые наблюдения:
1. Размер набора данных: (767, 9)
2. Распределение классов:
   - Без диабета: 500 случаев (65.2%)
   - С диабетом: 267 случаев (34.8%)

3. Корреляция признаков с Outcome:
   - Glucose: 0.492
   - BMI: 0.312
   - Age: 0.236

4. Статистика по возрасту:
   - Средний возраст: 33.2 лет
   - Медианный возраст: 29.0 лет
   - Минимальный возраст: 21 лет
   - Максимальный возраст: 81 лет

5. Статистика по BMI:
   - Средний BMI: 32.5
   - Медианный BMI: 32.3

Обработанные данные сохранены в файл 'pima_indians_diabetes_processed.csv'

Графики:

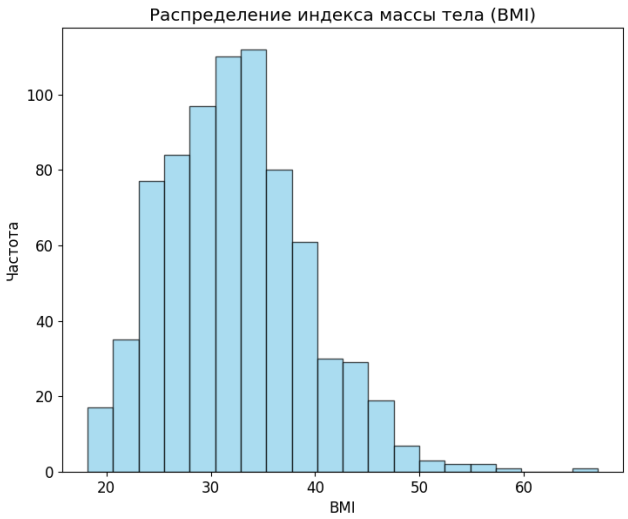
Распределение индекса массы тела (BMI)
Частота
BMI
0
20
40
60
80
100
20
30
40
50
60

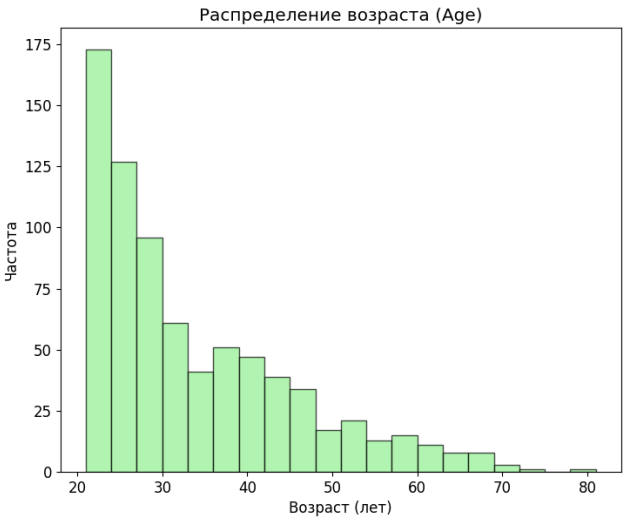
Распределение возраста (Age)
Частота
Возраст (лет)
0
25
50
75
100
125
150
175
20
30
40
50
60
70
80

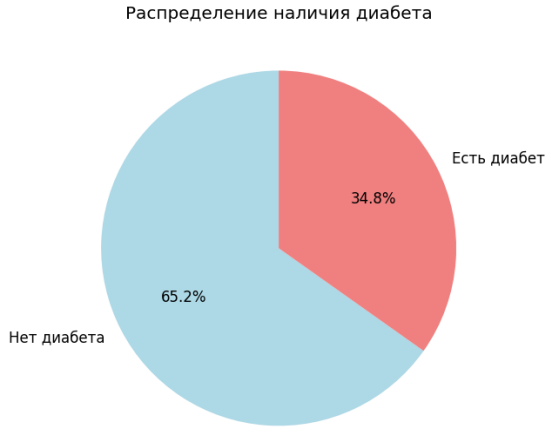
Распределение наличия диабета
Есть диабет
34.8%
65.2%
Нет диабета

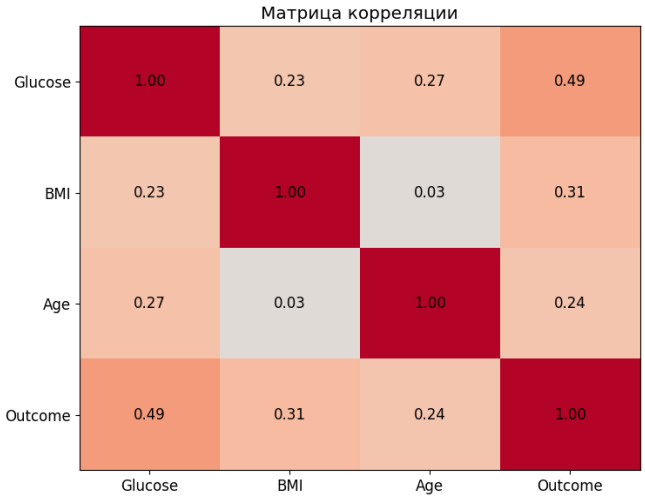
Матрица корреляции
Glucose
BMI
Age
Outcome
1.00
0.23
0.27
0.49
0.23
1.00
0.03
0.31
0.27
0.03
1.00
0.24
0.49
0.31
0.24
1.00

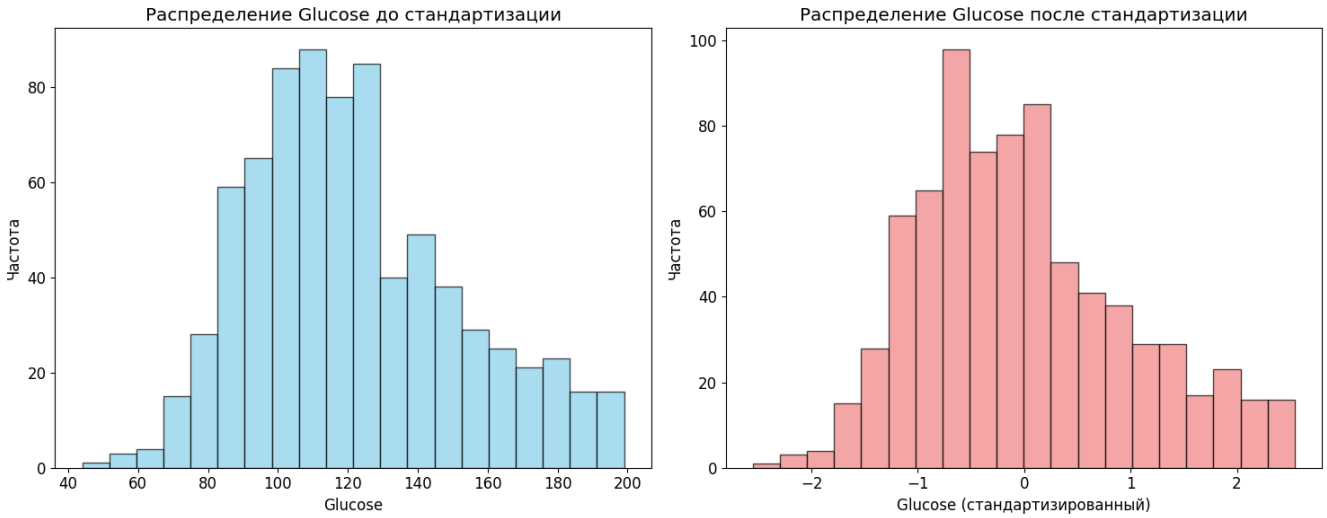

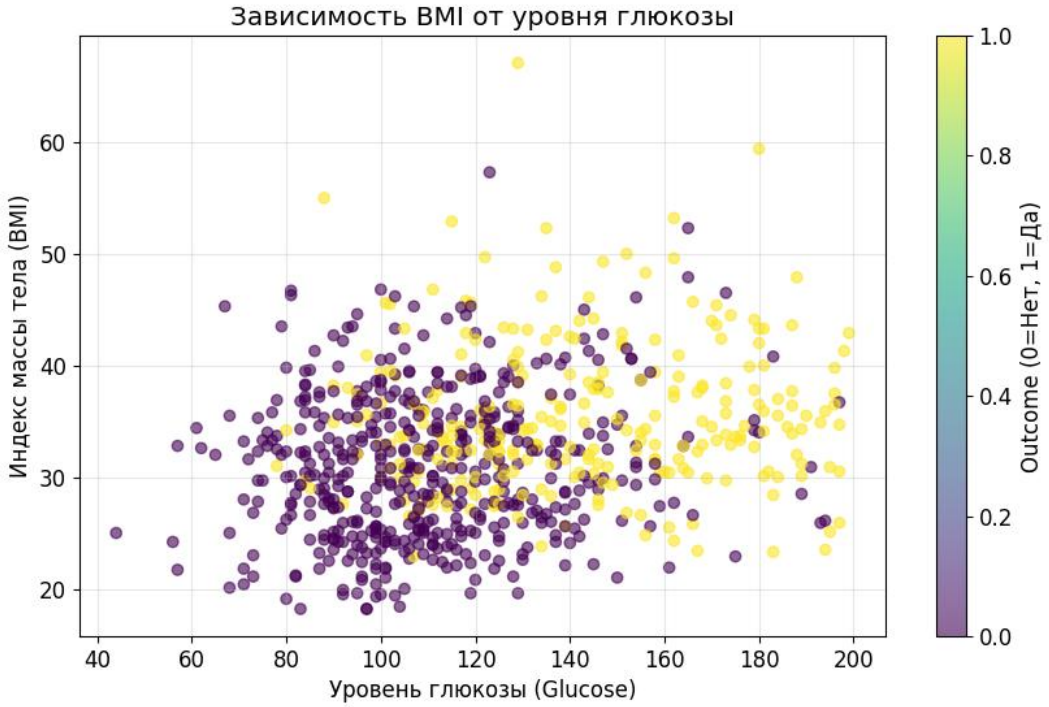

Вывод: в результате выполнения данной лабораторной работы получили практические навыки работы с данными с использованием библиотек Pandas для манипуляции и Matplotlib для визуализации. Научились выполнять основные шаги предварительной обработки данных, такие как очистка, нормализация и работа с различными типами признаков.