

Лабораторная работа № 2
По дисциплине "ОМО"
Тема: "Линейные модели для задач регрессии и классификации."

Выполнил:
Студент 3 курса
Группы АС-66
Невар В.А.
Проверил:
Крощенко А.А.

Цель: Изучить применение линейной и логистической регрессии для решения практических задач. Научиться обучать модели, оценивать их качество с помощью соответствующих метрик и интерпретировать результаты.

Вариант 5

Регрессия (Предсказание итоговой оценки студента)

1. Student Performance

2. Предсказать итоговую оценку (G3)

3. Задания:

- загрузите данные, выбрав в качестве признаков studytime, failures, G1, G2;
- обучите модель линейной регрессии;
- рассчитайте MAE и R2;
- визуализируйте зависимость G3 от G2 (оценка за предыдущий период) с линией регрессии.

Код:

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
from sklearn.linear_model import LinearRegression
from sklearn.metrics import r2_score, mean_absolute_error
from sklearn.model_selection import train_test_split

df = pd.read_csv("student-por.csv", sep=';')

print(f"Размерность данных: {df.shape}")
print("\nПервые 5 строк данных:")
print(df.head())

features = ['studytime', 'failures', 'G1', 'G2']
target = 'G3'

X = df[features]
y = df[target]

print(f"\nПризнаки (X): {X.shape}")
print(f"Целевая переменная (y): {y.shape}")

X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2,
random_state=42)

print(f"\nРазмер обучающей выборки: {X_train.shape}")
print(f"Размер тестовой выборки: {X_test.shape}")

model = LinearRegression()
model.fit(X_train, y_train)

y_pred = model.predict(X_test)

mae = mean_absolute_error(y_test, y_pred)
r2 = r2_score(y_test, y_pred)

print(f"\nРЕЗУЛЬТАТЫ МОДЕЛИ")
print(f"Mean Absolute Error (MAE): {mae:.4f}")
print(f"R-squared (R2): {r2:.4f}")

print(f"\nКоэффициенты модели:")
for i, feature in enumerate(features):
    print(f" {feature}: {model.coef_[i]:.4f}")
```

```

print(f"Свободный член (intercept): {model.intercept_:.4f}")

plt.figure(figsize=(15, 5))

plt.subplot(1, 3, 1)
plt.scatter(X_test['G2'], y_test, alpha=0.7, color='blue', label='Фактические значения')
plt.scatter(X_test['G2'], y_pred, alpha=0.7, color='red', label='Предсказанные значения')

sorted_indices = np.argsort(X_test['G2'].values)
G2_sorted = X_test['G2'].iloc[sorted_indices]
pred_sorted = y_pred[sorted_indices]

plt.plot(G2_sorted, pred_sorted, color='black', linewidth=2, label='Линия регрессии')
plt.xlabel('G2 (Оценка за второй период)')
plt.ylabel('G3 (Итоговая оценка)')
plt.title('Зависимость G3 от G2 с линией регрессии')
plt.legend()
plt.grid(True, alpha=0.3)

plt.subplot(1, 3, 2)
plt.scatter(y_test, y_pred, alpha=0.7)
plt.plot([y_test.min(), y_test.max()], [y_test.min(), y_test.max()], 'k--', lw=2)
plt.xlabel('Фактические значения G3')
plt.ylabel('Предсказанные значения G3')
plt.title('Фактические vs Предсказанные значения')
plt.grid(True, alpha=0.3)

plt.subplot(1, 3, 3)
residuals = y_test - y_pred
plt.scatter(y_pred, residuals, alpha=0.7)
plt.axhline(y=0, color='red', linestyle='--')
plt.xlabel('Предсказанные значения G3')
plt.ylabel('Остатки')
plt.title('Остатки модели')
plt.grid(True, alpha=0.3)

plt.tight_layout()
plt.show()

print(f"\nДОПОЛНИТЕЛЬНАЯ ИНФОРМАЦИЯ")
print(f"Среднее значение G3 в тестовой выборке: {y_test.mean():.2f}")
print(f"Стандартное отклонение G3 в тестовой выборке: {y_test.std():.2f}")
print(f"MAE относительно среднего: {(mae / y_test.mean() * 100):.2f}%")

print(f"\nПРИМЕР ПРЕДСКАЗАНИЯ")
sample_data = np.array([[2, 0, 14, 15]])
prediction = model.predict(sample_data)
print(f"Для студента с параметрами: studytime=2, failures=0, G1=14, G2=15")
print(f"Предсказанная итоговая оценка (G3): {prediction[0]:.2f}")

feature_importance = pd.DataFrame({
    'Признак': features,
    'Коэффициент': model.coef_,
    'Абсолютное значение': np.abs(model.coef_)
}).sort_values('Абсолютное значение', ascending=False)

print(f"\nВАЖНОСТЬ ПРИЗНАКОВ")
print(feature_importance)

print(f"\nКОРРЕЛЯЦИОННАЯ МАТРИЦА")
correlation_matrix = df[features + [target]].corr()
print(correlation_matrix)

```

Результат:

```
РЕЗУЛЬТАТЫ МОДЕЛИ
Mean Absolute Error (MAE): 2.6223
R-squared (R2): 0.0856


Кoeffициенты модели:
studytime: 0.8768
failures: -0.0000
G1: 0.1507
G2: -0.0298
Свободный член (intercept): 9.6768

ДОПОЛНИТЕЛЬНАЯ ИНФОРМАЦИЯ
Среднее значение G3 в тестовой выборке: 14.00
Стандартное отклонение G3 в тестовой выборке: 4.24
MAE относительно среднего: 18.73%

ПРИМЕР ПРЕДСКАЗАНИЯ
C:\Users\vadim\AppData\Local\Packages\PythonSoftwareFoundation.Python.3.11_qbz5n2kfra8p0\LocalCache\local-packages\Python311\site-packages\sklearn\utils\validation.py:2749: UserWarning: X does not have
valid feature names, but LinearRegression was fitted with feature names
warnings.warn(
Для студента с параметрами: studytime=2, failures=0, G1=14, G2=15
Предсказанная итоговая оценка (G3): 13.09

ВАЖНОСТЬ ПРИЗНАКОВ
Признак    Коэффициент    Абсолютное значение
0 studytime 8.767908e-01    8.767908e-01
2 G1 1.507163e-01    1.507163e-01
3 G2 -2.979943e-02    2.979943e-02
1 failures -5.551115e-17    5.551115e-17

КОРРЕЛЯЦИОННАЯ МАТРИЦА
studytime failures G1 G2 G3
studytime 1.000000 NaN 0.268689 0.305650 0.206725
failures NaN NaN NaN NaN NaN
G1 0.268689 NaN 1.000000 0.646733 0.687366
G2 0.305650 NaN 0.646733 1.000000 0.918617
G3 0.206725 NaN 0.687366 0.918617 1.000000
```



Вывод: Я изучил применил линейную и логистическую регрессии для решения практических задач. Научился обучать модели, оценивать их качество с помощью соответствующих метрик и интерпретировать результаты.